



Valutazione dell'incertezza di misura nei Digital Twin con Statistica Bayesiana

Laurea Magistrale in Ingegneria Matematica

Geard Koci (328626)

November 10, 2025



**Politecnico
di Torino**



Contenuti

1 Introduzione

► Introduzione

► Analisi Bayesiana con STAN

► Confronto teorico-sperimentale



Problema e Obiettivo della Tesi

1 Introduzione

Problema

- Descrivere in modo accurato il comportamento meccanico dei materiali.
- Le misure di **nanoindentazione** possono variare in condizioni ambientali diverse.
- Serve una stima più affidabile dei parametri che legano **forza** e **profondità**.

Obiettivo

- Stimare i parametri del modello in modo **robusto e interpretabile**.
- Utilizzare un approccio **bayesiano** con STAN.
- Sottolineare le differenze in condizioni sperimentali diverse.
- Creare strumenti in Python per generare e validare i dati.




Cos'è la Statistica Bayesiana

1 Introduzione

- Interpreta la probabilità come **grado di credenza**, non solo come frequenza.
- Combina le informazioni **a priori** con i **dati osservati**.
- Produce una distribuzione **a posteriori**, che rappresenta ciò che sappiamo dopo aver visto i dati.

$$p(\theta|D) \propto p(D|\theta) \pi(\theta)$$

Posterior = Likelihood × Prior



Fonte immagine: Researchgate.net
(https://www.researchgate.net/figure/Bayesian-updating-and-predictions-The-prior-distribution-repr-fig1_337219352)



Elementi chiave del paradigma bayesiano

1 Introduzione

Prior ($\pi(\theta)$)


Conoscenza iniziale o aspettativa sul parametro prima di osservare i dati.

Likelihood ($p(D|\theta)$)

Mostra quanto i dati sono compatibili con un certo valore di θ .

Posterior ($p(\theta|D)$)

Aggiornamento della credenza dopo aver visto i dati.



Fonte immagine: Researchgate.net

(<https://www.researchgate.net/figure/>


Example-of-Bayesian-inference-with-a-prior-distribution-a-posteriori
fig1_330577376)




Analisi del Dataset

1 Introduzione


- Due dataset sperimentali:
 - **Dataset 1:** aria condizionata spenta
 - **Dataset 2:** aria condizionata accesa
- Ogni dataset contiene 3 serie di test (16 prove ciascuna)
- Ogni prova registra: *Tempo*, *Forza*, *Profondità*, *SegmentID*, *Resistenza*



Set 1



Set 2



Set 3



Prima Stima dei Parametri

1 Introduzione

Come primo obiettivo si è voluta dare una prima stima delle diverse fasi dei nostri dati, utilizzando i seguenti modelli:

- **Modello Power Law** per fasi dinamiche:

$$F = a \cdot (h - h_0)^m$$

dove a è scala della risposta meccanica, h_0 la profondità di contatto ed m l'esponente plastico

- **Modello Costante** per le fasi di mantenimento:

$$F = c$$

La stima preliminare è ottenuta tramite massimizzazione della verosimiglianza con l'algoritmo: *Differential Evolution*.



Contenuti

2 Analisi Bayesiana con STAN

► Introduzione

► **Analisi Bayesiana con STAN**

► Confronto teorico-sperimentale



Come funziona STAN

2 Analisi Bayesiana con STAN

Definizione del modello
(likelihood + priors)



Campionamento
HMC/NUTS



Distribuzione
a posteriori
dei parametri

*Pipeline di Stan: dal modello ai
campioni della distribuzione a
posteriori.*

Cos'è Stan

Linguaggio probabilistico per **inferenza bayesiana** e **ottimizzazione**.
Consente di:

- Specificare modelli statistici in modo dichiarativo.
- Combinare conoscenze a priori e dati osservati.
- Ottenere **distribuzioni complete** dei parametri, non solo stime puntuali.

Motore di inferenza

Usa l'algoritmo **Hamiltonian Monte Carlo (HMC)** con estensione **No-U-Turn Sampler (NUTS)**, che esplora lo spazio dei parametri in modo efficiente anche in modelli complessi.



Modello e Struttura in Stan

2 Analisi Bayesiana con STAN

Struttura del modello

- Ogni segmento è descritto da parametri a_i e m_i distinti.
- Le costanti c_1 , c_2 , h_2 e h_3 garantiscono la **continuità** tra i segmenti.
- La verosimiglianza varia per ognuno dei 3 modelli successivi.
- Implementato in Stan con i blocchi: `data`, `parameters`, `transformed parameters`, `model`, `generated quantities`.

Il modello descrive l'intera prova di indentazione in 5 segmenti: *loading*, *hold1*, *unloading*, *hold2*, *unload_light*.

$$\mu_i = \begin{cases} a_1(h_i - h_1)^{m_1} & (\text{loading}) \\ a_1(h_k - h_1)^{m_1} = c_1 & (\text{hold1}) \\ a_2(h_i - h_2)^{m_2} & (\text{unloading}) \\ a_2(h_k - h_2)^{m_2} = c_2 & (\text{hold2}) \\ a_3(h_i - h_3)^{m_3} & (\text{unload_light}) \end{cases}$$

con $h_1 = 0$ e condizioni di continuità per h_2 , h_3

determinate dai segmenti precedenti.



Esecuzione e Valutazione del Modello

2 Analisi Bayesiana con STAN

Implementazione in R

- Il modello è eseguito tramite `rstan`, con 4 catene indipendenti.
- Ogni catena: 4000 iterazioni totali (2000 warmup), thinning pari a 2.

Metriche di Convergenza

- **R-hat ($\hat{R}$):** confronta la varianza tra catene e all'interno delle catene.

$$\hat{R} < 1.01 \Rightarrow \text{buona convergenza.}$$

- **Effective Sample Size (ESS):** stima il numero di campioni indipendenti effettivi.

$$ESS_{bulk}, ESS_{tail} > 400 \Rightarrow \text{stima affidabile.}$$

Queste metriche assicurano che le catene MCMC abbiano esplorato correttamente lo spazio dei parametri, garantendo stime robuste e interpretabili.



Modello Normale

2 Analisi Bayesiana con STAN

Verosimiglianza del modello:

$$F_i \sim \mathcal{N}(\mu_i, \sigma)$$

Table: Intervalli di credibilità 95%

Parametro	Dataset 1	Dataset 2
$m[1]$	[2.0368, 2.0473]	[2.0479, 2.0549]
$a[2]$	[0.0241, 0.0254]	[0.0503, 0.0519]
$m[2]$	[1.2088, 1.2189]	[1.0715, 1.0776]
$h_0[2]$	[149.17, 149.60]	[152.72, 152.95]
$c[1]$	[9.6858, 9.6967]	[9.8298, 9.8372]
$c[2]$	[0.9158, 0.9215]	[0.9946, 0.9980]




Figure: Fit modello normale — Dataset 2



Modello Log-Normale

2 Analisi Bayesiana con STAN

Verosimiglianza del modello:

$$\log(F_i) \sim \mathcal{N}(\log(\mu_i), \sigma_{\log})$$

Table: Intervalli di credibilità 95%

Parametro	Dataset 1	Dataset 2
$m[1]$	[1.9674, 1.9751]	[1.8800, 1.8849]
$a[2]$	[0.0001, 0.0001]	[0.0093, 0.0102]
$m[2]$	[2.1457, 2.1934]	[1.3780, 1.3959]
$h_0[2]$	[106.02, 108.22]	[140.02, 140.74]
$c[1]$	[9.8633, 9.9163]	[9.7985, 9.8342]
$c[2]$	[0.9835, 0.9866]	[1.0069, 1.0097]




Figure: Fit modello log-normale — Dataset 2



Modello Gamma

2 Analisi Bayesiana con STAN

Verosimiglianza del modello:

$$F_i \sim \text{Gamma}(\alpha, \mu_i)$$

$$E[F_i] = \mu_i, \quad \text{Var}(F_i) = \frac{\mu_i^2}{\alpha}$$

Table: Intervalli di credibilità 95%

Parametro	Dataset 1	Dataset 2
$m[1]$	[1.8417, 1.8490]	[1.8605, 1.8656]
$a[2]$	[0.0003, 0.0003]	[0.0112, 0.0124]
$m[2]$	[1.9990, 2.0414]	[1.3415, 1.3604]
$h_0[2]$	[111.90, 113.83]	[141.37, 142.11]
$c[1]$	[9.6684, 9.7255]	[9.7776, 9.8156]
$c[2]$	[0.9919, 0.9953]	[1.0109, 1.0129]




Figure: Fit modello Gamma — Dataset 2



Contenuti

3 Confronto teorico-sperimentale

► Introduzione

► Analisi Bayesiana con STAN

► Confronto teorico-sperimentale



Modello per la Generazione di Nuovi Dati

3 Confronto teorico-sperimentale

Obiettivo: simulare nuovi cicli di nanoindentazione basandosi sulle leggi fisiche osservate.

Generazione della forza sintetica:

$$F(t) = \begin{cases} \text{loading_rate} \cdot t & \text{loading} \\ F_{\max} & \text{hold1} \\ F_{\max} - \text{unloading_rate} \cdot (t - t_2) & \text{unloading} \\ F_{\text{intermediate}} & \text{hold2} \\ F_{\text{intermediate}} \cdot \left(1 - \frac{t - t_4}{t_{\text{unload}}}\right) & \text{unload_light} \end{cases}$$

Modello inverso utilizzato:

$$h_i = \begin{cases} \left(\frac{F_i}{a_1}\right)^{1/m_1} + h_1 & (\text{segment}_i = 1) \\ \left(\frac{c_1}{a_1}\right)^{1/m_1} + h_1 & (\text{segment}_i = 2) \\ \left(\frac{F_i}{a_2}\right)^{1/m_2} + h_2 & (\text{segment}_i = 3) \\ \left(\frac{c_2}{a_2}\right)^{1/m_2} + h_2 & (\text{segment}_i = 4) \\ \left(\frac{F_i}{a_3}\right)^{1/m_3} + h_3 & (\text{segment}_i = 5) \end{cases}$$

Il modello inverso traduce il profilo di forza $F(t)$ in profondità sintetiche $h(t)$, ricostruendo l'intero ciclo di nanoindentazione.



Input e Output del Notebook

3 Confronto teorico-sperimentale

Input richiesti all'utente:

- Attivazione o meno del **controllo termico**.
- **Velocità di carico e scarico** (loading/unloading rate).
- **Durata temporale** di ciascuna fase.

Output automatici generati:

1. Profilo temporale della forza $F(t)$.
2. Risposta in spostamento $h(t)$.
3. Curva forza-spostamento completa.
4. File di dati (.txt) con tempi, forze e spostamenti per fase.




Figure: Dataset con controllo termico



Validazione dei Dati Sperimentali

3 Confronto teorico-sperimentale

Obiettivo. Verificare se nuovi dati sperimentali seguono l'andamento teorico del modello.

Metriche principali:

- **Errore Relativo Medio**

$$\text{ERM} = \frac{1}{N} \sum_{i=1}^N \left| \frac{h_{\text{sper}}(i) - h_{\text{teorico}}(i)}{h_{\text{sper}}(i)} \right| \times 100\%$$

- **Correlazione di forma (Pearson)** sulle differenze locali

$$r = \text{corr}(\Delta h_{\text{sper}}, \Delta h_{\text{teorico}})$$

Interpretazione rapida: ERM misura l'accuratezza percentuale; r valuta se la curva sperimentale cambia di pendenza come quella teorica (indipendente da offset).



Risultati della Validazione

3 Confronto teorico-sperimentale

Dataset con controllo termico

- Errore Relativo Medio: **6.30%**
- Correlazione Forma: **0.9527**

Ottimo allineamento con il modello teorico. Le curve sperimentali e teoriche coincidono quasi perfettamente nelle fasi di loading e unloading.

Dataset con modello e dati incoerenti

- Errore Relativo Medio: **9.81%**
- Correlazione Forma: **0.9451**

Il modello con controllo termico applicato a dati senza controllo evidenzia scostamenti più marcati: l'errore cresce, la correlazione diminuisce, segnale di **non compatibilità fisica** tra i due casi.



Valutazione dell'incertezza di misura nei Digital Twin con Statistica Bayesiana

Grazie dell'attenzione!